UNIVERSIDADE FEDERAL DE JUIZ DE FORA

IGOR PIRES

LUIS AUGUSTO TOSCANO GUIMARÃES

HASHMUSIC

JUIZ DE FORA - MG

2014

SUMÁRIO

1. ATIVIDADES REALIZADAS PELOS MEMBROS 1

2. ALGORITMOS IMPLEMENTADOS 2

3. FUNÇÕES DE HASH 5

3.1. FUNÇÕES HASH DE DIRETÓRIO 5

3.2. FUNÇÕES HASH DE NOME 6

4. GRÁFICOS SOBRE ÍNDICES DE COLISÃO 6

5. ANÁLISE SOBRE OS RESULTADOS OBTIDOS 10

1. ATIVIDADES REALIZADAS PELOS MEMBROS

O trabalho tem como objetivo criar um software que simule operações básicas (Armazenamento e busca) de carregamento de dados em dispositivos multimídia portáteis, como o *IPod Classic*, que possui baixo poder de processamento e grande capacidade de armazenamento e, ainda assim, consegue ser mais eficiente que outros dispositivos que possuem uma menor capacidade de armazenamento, para tal, será utilizado técnicas de hashing e de ordenação de registros, o que garante tempos melhores nestas operações. Para a realização do trabalho foi formado o grupo entre Igor Pires dos Santos e Luis Augusto T. Guimarães e a divisão de tarefas foi realizada em forma de papéis:

• Papel 1: Definição de 3 funções de hash para alocação em pastas, testes com as funções e geração dos gráficos

• Papel 2: Definição de 3 funções de hash para alteração do nome dos arquivos, testes com as funções e geração dos gráficos

• Papel 3: Códigos para inserção da música no sistema, leitura das tags ID3 dos arquivos, criação de um arquivo "music.dat", renomeação da música e alocação na pasta correta.

• Papel 4: Códigos para geração dos relatórios ordenados solicitados pelo usuário.

Para uma melhor distribuição de tarefas entre os integrantes do grupo, os papéis foram atribuídos da seguinte forma: A decisão sobre quais funções de hash seriam utilizadas tanto para alocação dos diretórios quanto para a alteração dos nomes dos arquivos ficaram a cargo dos dois integrantes, já a implementação das funções, o integrante Luis Augusto ficou responsável pela implementação das funções de diretório e o integrante Igor ficou responsável pela implementação das funções de alteração do nome dos arquivos; A implementação dos algoritmos de inserção de músicas no sistema, que envolvem a operação de ler tags ID3 dos arquivos MP3, a criação de um arquivo "music.dat" para armazenar informações das músicas importadas para o repositório, a alocação na pasta correta e a renomeação das músicas ficou a cargo do integrante Luis Augusto; A implementação de algoritmos para a

geração de relatórios, a ordenação de registros e os gráficos sobre colisões ficou a cargo do integrante Igor.

2. ALGORITMOS IMPLEMENTADOS

Os algoritmos em si serão colocados em apêndice, pois, são extensos e podem dificultar a leitura, este tópico apresentará como a interface do software funciona e a ideia básica do algoritmo por trás dela.

A linguagem de programação utilizada para a implementação dos algoritmos foi a linguagem Java. A escolha foi determinada pela fácil portabilidade do código entre os sistemas mais comuns do mercado como o Windows/Linux e também devido a melhor afinidade dos integrantes do grupo com a linguagem. Para a interface gráfica foi utilizada uma API própria da linguagem Java chamada Swing.

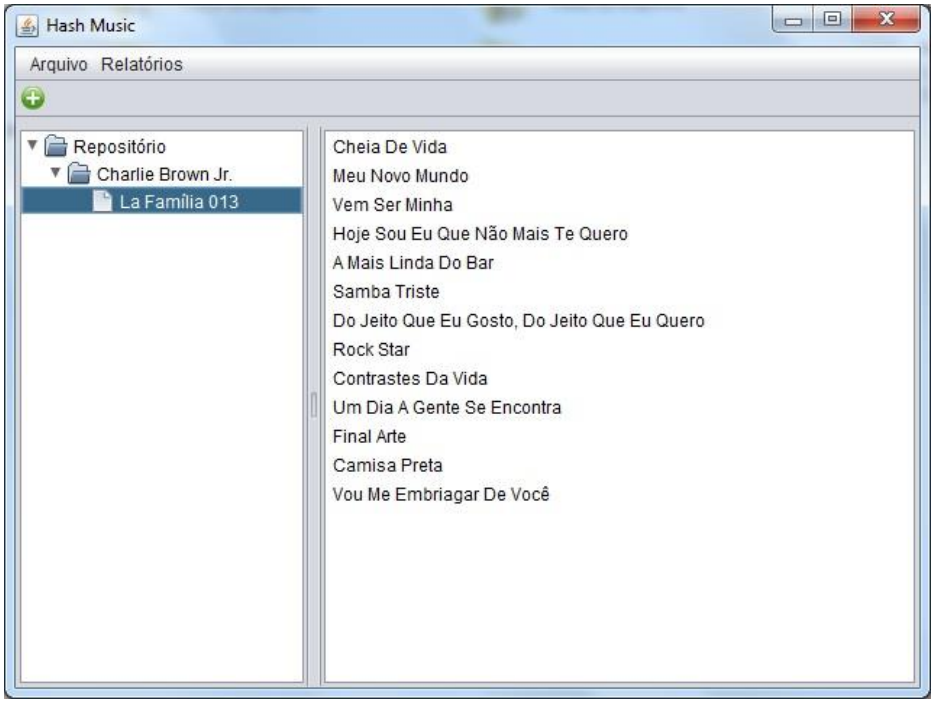

Figura: Tela inicial do software (HashMusic)

A interface básica do software apresenta a seguinte configuração: Um menu superior aonde há os menus "Arquivos" e "Relatórios", sendo que o menu

"Arquivos" possui um simples submenu com a função de sair; Um botão que possibilita a importação de novas músicas para o repositório; uma árvore na lateral esquerda que lista a hierarquia de Artistas->Álbuns das músicas adicionadas no repositório; Uma lista de músicas que é preenchida ao selecionar uma hierarquia Artista->Álbum.

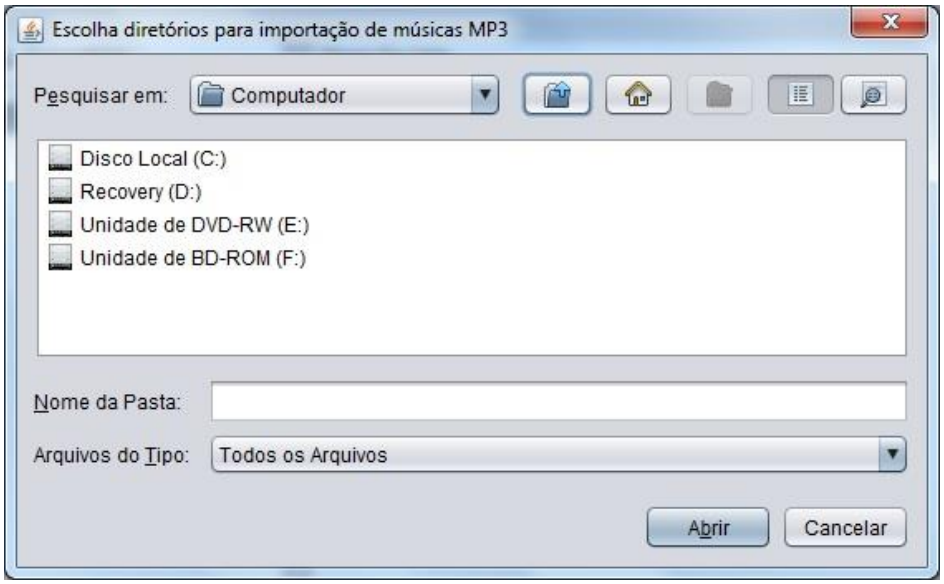

Figura: Janela para a escolha de diretórios para importação

Os algoritmos mais importantes do software são o de importação das músicas e o de ordenação. O de importação funciona da seguinte forma: Ao clicar no botão de importação é aberta uma janela de diálogo que possibilita selecionar um ou mais diretórios. Ao usuário selecionar os diretórios que deseja é aberta uma janela de progresso indeterminado. Neste momento o programa cria um nova thread que executa os processos de importação, evitando que a interface fique congelada enquanto a importação ocorre. O processo de importação se baseia nos seguintes passos: Para cada diretório que o usuário selecionou, um algoritmo encontra todos os arquivos, filtrando pela extensão ".mp3", da raiz do diretório e faz uma chamada recursiva para todos os seus subdiretórios, desta forma, dada uma pasta, eu irei encontrar todos os arquivos Mp3 contidos na raiz desta pasta e em seus subdiretórios. Ao término desta operação, cada Mp3 que foi encontrado é processado da seguinte forma: Primeiro o algoritmo verifica se o arquivo contém tags ID3 e se estão devidamente preenchidas (Artista, Álbum e Título), o próximo teste é verificar se a música já não existe no

repositório, só é adicionado novas músicas ao repositório se elas não existirem. Passando pelos testes, um novo objeto MusicInfo (Classe que o sistema usa para guardar informações das músicas) é criado e preenchido com as informações da tag ID3. O próximo passo é gerar o hash para a alocação do diretório correto, para isto, existe uma função chamada getHashDir que recebe um MusicInfo como parâmetro e retorna a String do hash, definimos que a chave para o hash de diretório seria a combinação: Nome do artista + '#' + Nome do álbum, gerado o hash, existe uma verificação se o diretório existe ou não, caso não exista é criado um novo diretório, ou seja, a criação é sob demanda. Após este processo, é gerado o hash para a alteração do nome do arquivo, da mesma forma, há um método chamado getHashName que faz o processo de geração do hash, neste caso, definimos que a chave seria: Nome do artista + '#' + Nome do álbum + '#' + Título da música. Para facilitar a troca de funções para os testes e também manter o código modularizado, criamos interfaces como "IHashDirectory" que deve ser implementada por funções de hash para diretório e "IHashName" que deve ser implementada por funções de hash para alteração do nome dos arquivos. Desta forma, para alterar a função que gera o hash do diretório, basta trocar a instância da classe que implementa a interface "IHashDirectory", o mesmo é válido no caso das funções de alteração do nome do arquivo. Com o hash do diretório e do nome do arquivo, o algoritmo concatena os dois em formato de caminho de sistema de arquivos e copia a o MP3 para o lugar e com o nome corretos. Terminado esses processos para cada arquivo MP3 encontrado dos diretórios selecionados pelo usuário para a importação, é gerado um arquivo "music.xml" e um arquivo "importLog.xml". O arquivo "music.xml" guarda a lista de informações de todas as músicas do repositório, já o "importLog.xml" guarda informações de possíveis erros que tenham ocorrido durante o processo de importação, contendo qual arquivo MP3 ocorreu o problema e a mensagem de erro. A escolha pelo formato XML foi feita para simplificar a leitura e escrita destes arquivos.

Quanto aos algoritmos de ordenação era necessário que fossem estáveis por haver a necessidade de manter a posição original entre objetos de mesmo valor, portanto escolhemos o Merge Sort.

O Merge Sort funciona dividindo o objeto List pela metade até que este tenha tamanho um, de maneira recursiva, e quando estes são unidos (processo de Merge) sempre teremos listas ordenadas de suas duas metades então basta uni-las em outro objeto List<> percorrendo ambas as listas, comparando-as e adicionando sempre o menor objeto. Porém neste caso a comparação era entre objetos String e para que possamos fazer a comparação entre estes objetos é necessário usar o método String.compareToIgnoreCase(String) que compara os dois objetos e retorna um inteiro, caso seja menor do que zero a primeira String é maior do que a segunda e vice-versa.

O mesmo funcionou para os objetos MusicInfo, já que suas propriedades álbum e artista eram Strings, só houve diferença na ordenação de artista e álbum, pois somente quando os artistas eram iguais se comparava o álbum.

3. FUNÇÕES DE HASH

Foram desenvolvidas seis funções de hash sendo três destas para diretórios e outras três para no nome do arquivo mp3.

3.1. FUNÇÕES HASH DE DIRETÓRIO

O primeiro hash de diretório foi o hash de divisão que soma todos os caracteres da String em um inteiro e pega o módulo deste inteiro com um número primo e em seguida pega o módulo desta divisão com o tamanho da tabela, retornando o este segundo módulo em String.

O segundo hash utilizado foi o hash de extração, que divide o String em duas metades, concatena a segunda metade com a primeira, ou seja, inverte suas metades, em seguida pega os cinco caracteres do meio dessa nova String, soma estes e retorna o módulo da soma com o tamanho da tabela em String.

Por último foi utilizado o hash java, que pega cada caractere da chave e multiplica-os por uma potência decrescente de 31 e soma os resultados, supondo uma chave de 3 caracteres a soma se daria da seguinte forma:

- O 1º caractere é multiplicado por 31^2
- O 2º caractere é multiplicado por 31^1
- O 3º caractere e multiplicado por 31^0

Ao fim da soma é retornado o módulo desta pelo tamanho da tabela em String.

3.2. FUNÇÕES HASH DE NOME

O primeiro hash de nome foi o hash da multiplicação que primeiro realiza a soma de todos os caracteres da String e os multiplica pelo resultado da divisão entre o tamanho da String e um número primo retornando o valor da multiplicação em String.

O segundo hash utilizado foi o hash de meio-quadrado que soma todos os caracteres e eleva a soma ao quadrado e caso o resultado seja maior que o valor máximo os caracteres máximos do meio são selecionados e retornados em String caso contrário retorna-se apenas o resultado da potência.

E por último foi utilizado o hash pires que se assemelha ao hash do meio-quadrado, pois novamente realiza a soma e eleva o seu resultado ao quadrado, porém o resultado é colocado na base vinte para que o resultado tenha um tamanho ainda menor, caso o resultado ainda seja maior que o valor máximo para hashings de nome, novamente, os caracteres máximos do meio são selecionados e retornados em String caso contrário retorna-se apenas o resultado da potência na base vinte.

4. GRÁFICOS SOBRE ÍNDICES DE COLISÃO

Primeiramente foram analisados os hashs de diretório, começando pelo hash da divisão. No qual percebemos que este hash possui um número crescente de colisões, chegando a ter 402 colisões em 500 músicas, ou seja, possui um valor médio de colisões muito alto, entretanto suas colisões são bem espalhadas.

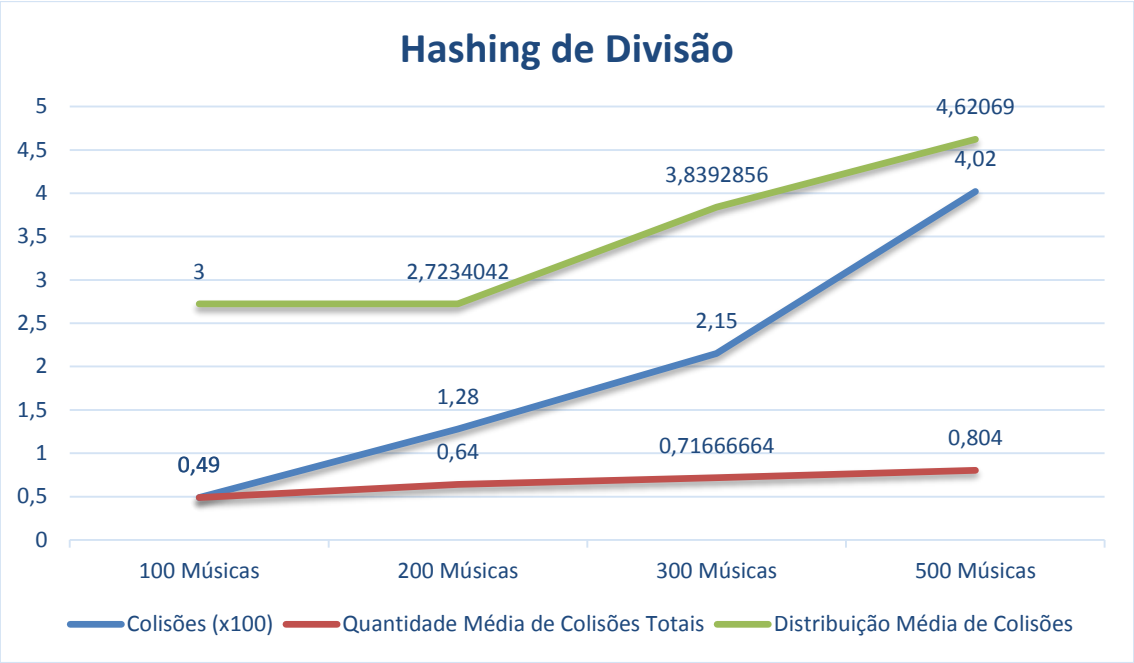

Para o hashing de extração o mesmo vale, possuindo 410 colisões com 500 músicas, ou seja, um valor médio de colisões superior ao da divisão e estas colisões ainda são menos distribuídas que a do hashing de divisão.

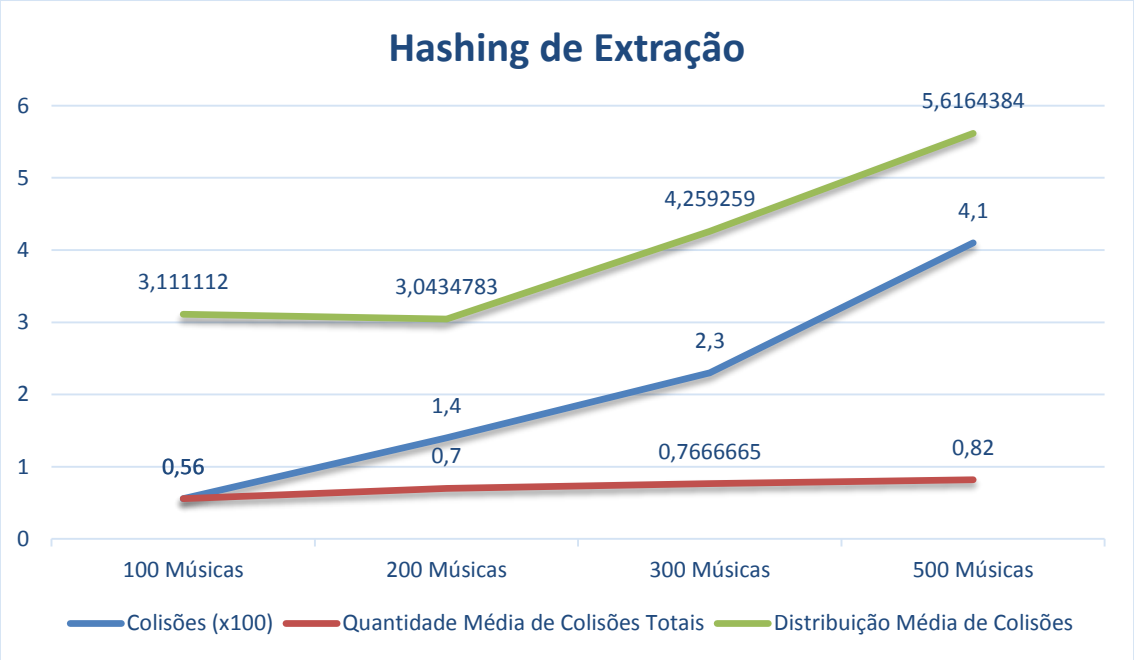

Em seguida foi analisado o hash java, que foi considerado o pior, pois possui o nível mais elevado de colisões e estes ainda menos distribuidos, chegando a distribuição média de 17,73.

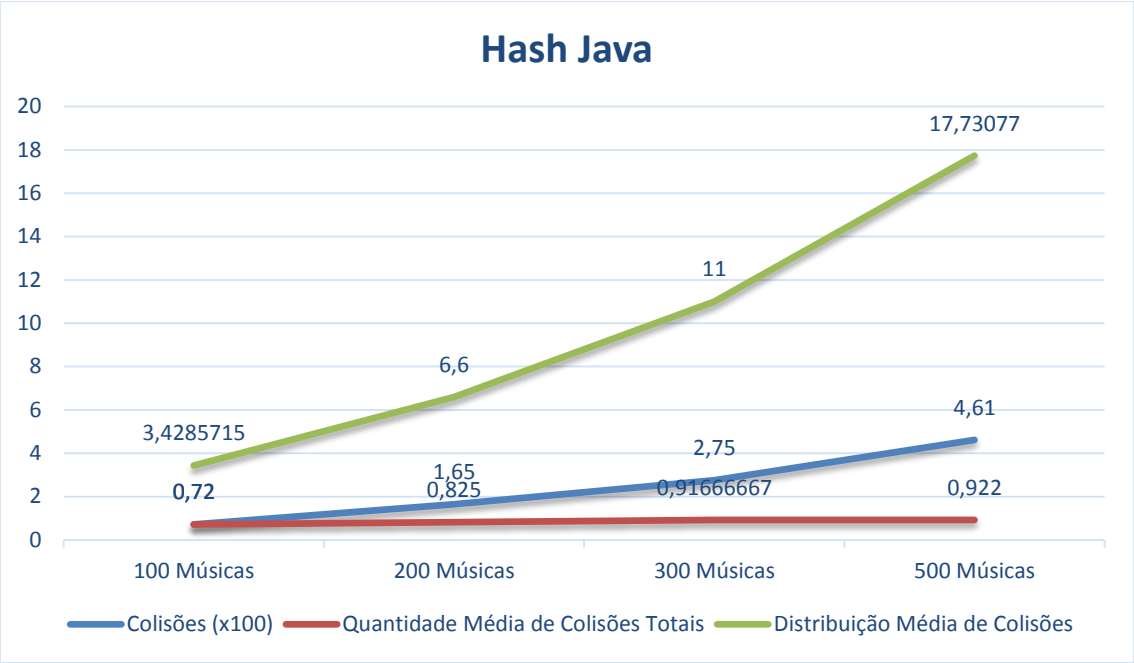

Em seguida foram analisados os hashs de nome, começando pelo hash de multiplicação. Este hash surpreendeu por ser extremamente simples e não ter apresentado nenhuma colisão.

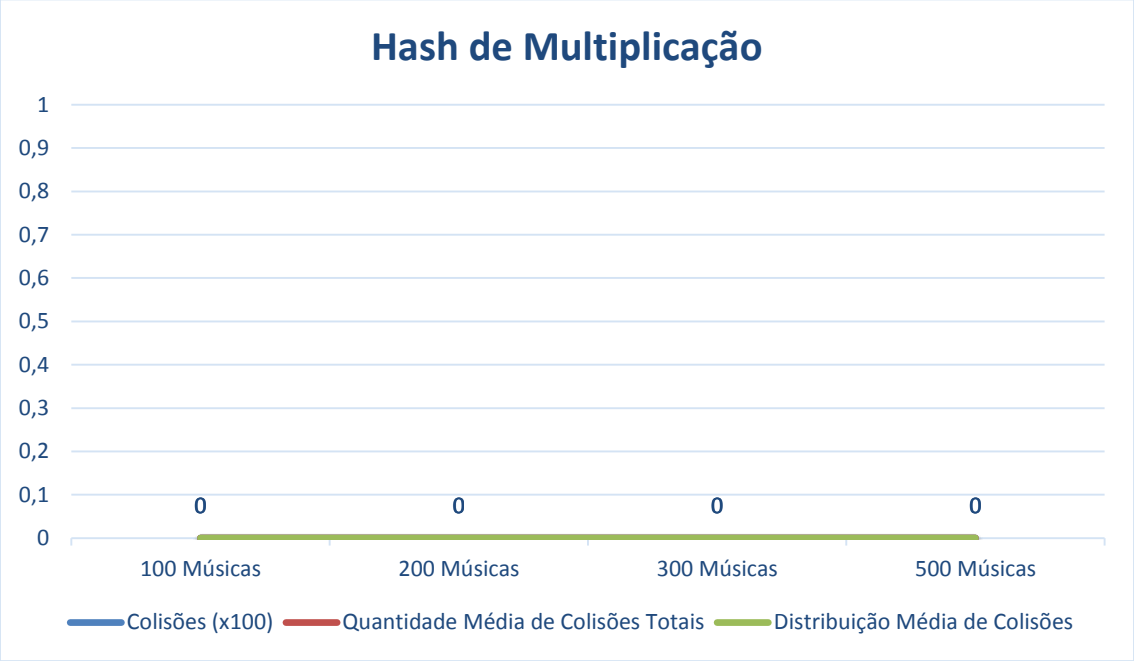

Já o hash de meio-quadrado apresentou o valor máximo de 26 colisões sendo estas bem distribuidas tendo 2 colisões com o mesmo nome (por isso 1,04 na distribuição média de colisões). E sua quantidade média de colisões totais foi menor do que 10%.

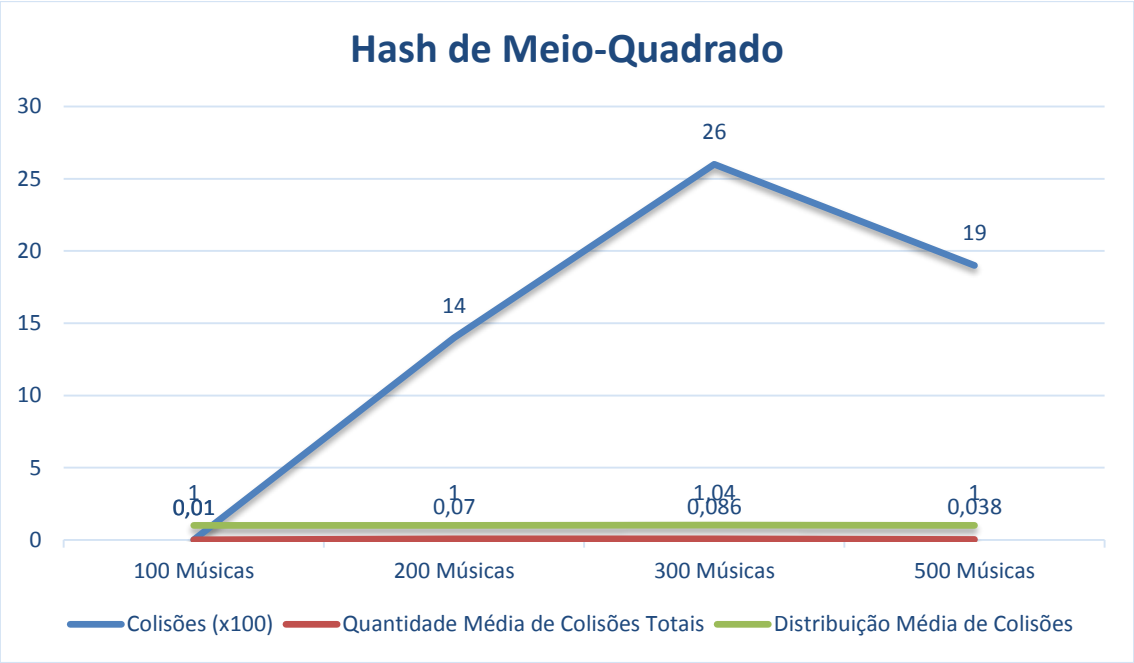

Já o hash pires obteve exatamente as mesmas colisões que o hash meio-quadrado, por estes funcionarem da mesma forma, tendo como diferença apenas a base em que os resultados são exibidos.

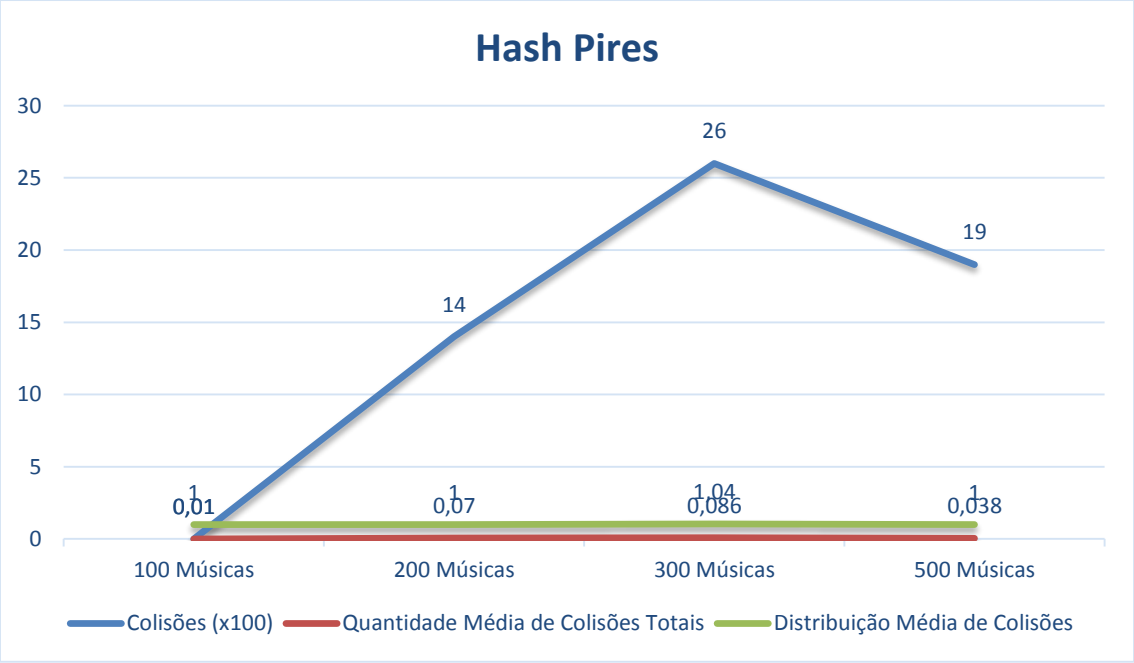

5. ANÁLISE SOBRE OS RESULTADOS OBTIDOS

Ao final do trabalho obtivemos um programa capaz de incluir bibliotecas de música, ordená-las rapidamente e dispensamos a necessidade de armazenar o caminho para cada uma delas.

Quanto à interface o programa possui poucos botões, tornando-se uma interface fácil de ser utilizada, apresentando as músicas separadas por artista e álbum e relatórios de colisão.

Quanto as funções de hashing, estas tiveram um bom funcionamento, visto que a intenção dos hashs de diretório era agrupar em pastas as músicas que tinha artista e álbum semelhantes, por isso o grande número de colisões, e o hash de nome selecionado não apresentou nenhuma colisão.